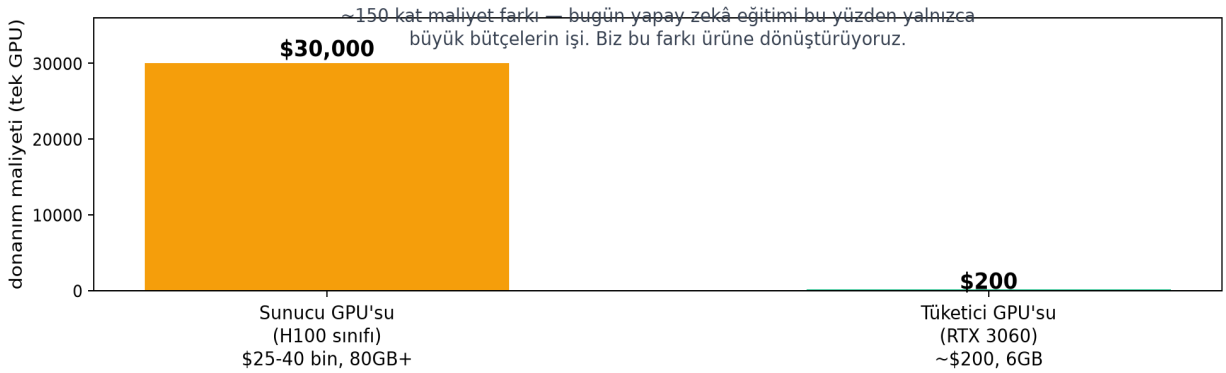
YATIRIMCI ÖZETİ

Büyük Dil Modeli Eğitimini 6 GB'lık Bir Laptop GPU'suna Sığdırdık

Bugün 1 milyar+ parametreli bir modeli eğitmek, tek parçası 25-40 bin dolar olan sunucu GPU'ları ve yüzbinlerce dolarlık eğitim bütçeleri gerektiriyor. Geliştirdiğimiz teknoloji yığını, aynı eğitimi **~200 dolarlık bir tüketici GPU'sunda (6 GB)** çalıştırılabilecek hale getiriyor — rakiplerin aynı donanımda deneyemediği ölçekte.



SORUN

Yapay zekâ eğitimi bir donanım yarışı hâline geldi: model büyüdükçe bellek ve hesap ihtiyacı katlanıyor, eğitim maliyetleri milyon dolarları buluyor. Sonuç: bu alanda çalışabilenlerin sayısı, bütçesi büyük olanlarla sınırlı. Oysa dünyada milyonlarca güçlü tüketici GPU'su (6-8 GB) mevcut — ve bugün bu donanımın tamamı "yetersiz" sayıldığı için yapay zekâ eğitiminde kullanılamıyor.

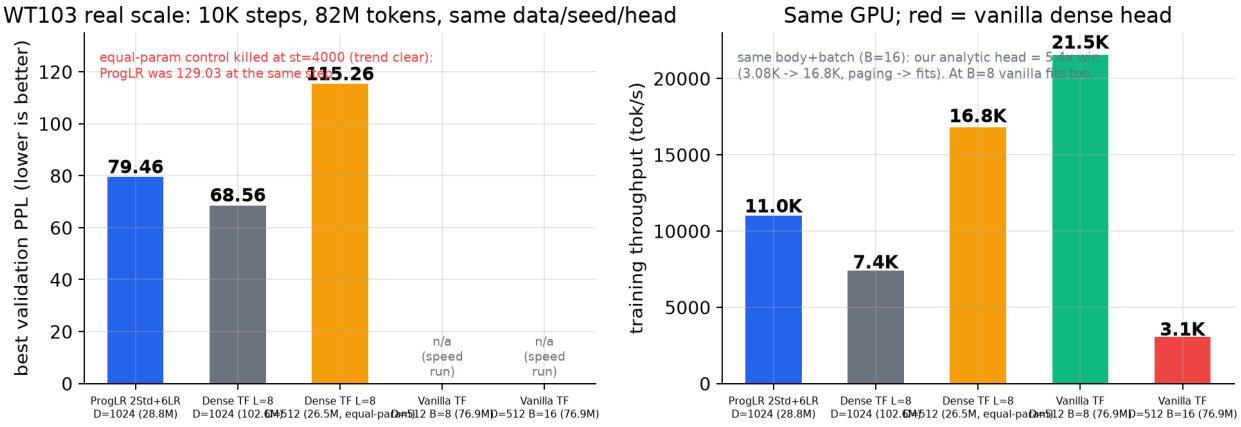
ÜRÜNÜMÜZ — DÖRT TEKNOLOJİ, TEK HEDEF: AYNI İŞ, ÇOK DAHA UCUZ

Teknoloji	Ne yapıyor	Ölçülen kazanç
V3-Embed (kelime hazinesi sıkıştırma)	Modelin kelime hazinesi matrisini çok küçük öğrenilebilir faktörlere indiriyor; kelime sayısı artık belleği şişirmiyor.	500× sıkıştırma
Analytic Chunked Head (çıktı katmanı hızlandırıcı)	50.000-250.000+ kelimelik çıktı katmanının eğitimini matematiksel olarak aynı sonucu veren, bellek dostu bir yöntemle hesaplıyor.	5-12× hızlanma; bellek taşmasını bitiriyor
Progressive Low-Rank (dar kapasiteli gizli katmanlar)	Gizli katmanların bir kısmını düşük maliyetli eşdeğerlerine çeviriyor; geniş modelleri 6 GB bütçeye sığdırıyor.	Aynı genişlikte ~3.6× az parametre

NCE Sampled Head (hız katlaması)	Çıktı katmanını tüm kelimeler yerine hedef + örneklenen negatiflerle eğitiyor; hesap maliyeti kelime sayısından tamamen bağımsızlaşıyor. NCE ile ısınma, exact CE ile son rötuş (hibrit) hem hızı hem kaliteyi veriyor.	3-4.4× ek hızlanma; hibrit ile kalite kaybı ~%4

KANIT — AYNI 6 GB GPU'DA ÖLÇÜLDÜ

Ölçüm	Vanilya yaklaşım (rakiplerin yöntemi)	Bizim teknolojimiz
Eğitim hızı (aynı model, aynı batch)	3.1K token/sn — bellek taşması (9.1GB)	16.8K token/sn — 5.4× daha hızlı, 6 GB içinde
250.000 kelimelik model	Daha başlatılamıyor (çıktı katmanı tek başına ~8GB)	6 GB içinde eğitildi (~25 dakika son finetune)
WikiText-103 modeli (50K kelime)	Aynı yükte bellek page'leniyor	val PPL 95.18 — 6 GB'da, ~9 GPU-saat
229M parametreli yoğun model	6 GB'a sığmıyor (sürekli bellek taşması)	Düşük maliyetli eşdeğeri 2.8 GB'da çalışıyor
250K kelimelik model eğitim hızı (aynı model)	5.0K token/sn (exact CE)	14.9K token/sn — NCE ile 3×
8.9M parametreli model eğitim hızı (aynı model)	20.6K token/sn	90.9K token/sn — 4.4×
Kalite + hız (hibrit: NCE ısınma, exact rötuş)	14 dakikada 224.21 (exact CE 2000 adım)	Aynı sürede 233.10 — kalitenin %96'sı, saf NCE'nin 3.5× az süresi



Aynı donanım, aynı model gövdesi, aynı batch boyutu: kırmızı sütun vanilya (rakiplerin) yöntemi; mavi/turuncu sütunlar bizim teknolojimizle eğitilen modeller. Kırmızı nokta: vanilyanın deneyemediği ölçekte biz eğitiyoruz.

NEDEN ŞİMDİ, NEDEN BİZ

• Pazar açılımı: eğitim maliyeti 30-100× düşünce, bugün "yapay zekâ modeli geliştirmek çok pahalı" diyen binlerce şirket ve araştırma ekibi bu işe girebilir — kendi verisiyle, kendi donanımında.

• Savunulabilir ürün: bellek-sınır optimizasyonu, rakiplerin aynı donanımda uygulayamadığı ölçekte kazanç sağlıyor (250K kelime hazinesi, geniş modeller). Dört patentlenebilir bileşen: V3-Embed, analytic chunked head, progressive low-rank, NCE

sampled head.

• Kanıt zinciri: tüm sonuçlar tek bir 6 GB'lık GPU üzerinde, karşılaştırmalı koşularla ölçüldü; eğitim hızlandırıcının matematiksel eşdeğerliği bit-bit doğrulandı.

• Düşük girdi maliyeti: yığının tamamı ~200 dolarlık donanımda geliştirildi — ürünleşme de aynı donanım sınıfını hedefliyor.

DÜRÜST SINIRLAR

Şeffaflık adına: eşit parametre sayısında ve küçük ölçekte, klasik yoğun mimari kalite açısından önde kalabiliyor. NCE hız katmanı bir tahmincidir — aynı adım sayısında doğrulama kalitesi (val PPL) exact CE'nin ~2.8× gerisindedir; kazandırdığı ~4.4× hız, aynı sürede çok daha fazla veri/model işlenmesini sağlar ve kelime sayısından bağımsız ölçeklenir. Kalite metriği olarak exact CE esas alınır. Bizim kazancımız rakiplerin **deneyemediği** ölçektedir (geniş model + büyük kelime hazinesi + tüketici GPU'su) — ürünümüz de tam olarak bu bölgeyi hedefler. Model kalitesi iddiamız, ölçülebilir dil-modeli metriğinde (val PPL) kıyaslanabilir değerler üretmektir; "daha az parametreyle aynı kalite" gibi bir sihir iddia etmiyoruz.

SONRAKİ ADIMLAR

• Demo: aynı laptop üzerinde canlı eğitim + 250K kelimelik model ile metin üretimi (saniyede ~100 kelime).

• Teknik rapor: tüm ölçümlerin, grafiklerin ve doğrulama adımlarının bulunduğu 12 bölümlük doküman (FINAL_REPORT.pdf).

• Görüşme: yatırım teklifi, yol haritası ve pazara giriş planı için 30 dakikalık toplantı.

V3 Projesi — 6 GB'da LLM Eğitimi | Taslak, görüşme öncesi | Ağustos 2026